Projet RITAL - Reproduction de Papier

On the Benefit of Incorporating External Features in a Neural Architecture for Answer Sentence Selection

Cai Gautier, Keddis Adam, Théologien Antoine (Les Pupuces)

May 17, 2025

Sujet du Papier et Contributions Générales

- **Sujet principal** : Sélection de réponse (Answer Sentence Selection) dans les systèmes Question/Réponse (QA).
- **Observation clé** : Les architectures neuronales négligent souvent les features externes.
- **Hypothèse** : Les features externes peuvent compléter les réseaux neuronaux.
- **Contribution** : Ajouter des features simples à un réseau convolutionel (CNN) améliore les performances.

Positionnement par rapport à l'État de l'Art

- Expérimentation sur deux benchmarks reconnus : **WikiQA** et **TRECQA**.
- Le Deep Learning domine les approches QA (CNN, LSTM, attention).
- Les anciennes features utiles sont souvent ignorées.
- L'article explore si elles sont toujours pertinentes.
- Comparaison de CNN seul et CNN + features à d'autres modèles de l'état de l'art.

Description du Modèle Proposé

- **Architecture CNN** : bi-CNN inspirée de Severyn et Moschitti.
- **Embeddings** : 50D (Wikipedia), 300D (Google News).
- **21 features externes**, en 3 catégories :
  - Lexical/semantic matching : BM25, Word2Vec, ESA, TAGME.
  - Readability : syllabes, mots complexes, Dale-Chall.
  - Focus : MatchedNGram sur les head words.
- **Fusion** dans la couche fully-connected.

Forces de la Contribution

- **Amélioration significative** sur TREC QA et WikiQA.
- **+10.8% en S@1** sur WikiQA dans certaines configs.
- **Compétitif avec PairwiseRank, ABCNN-3**.
- Montre que les CNN seuls ne capturent pas tout.
- Soutient l'usage conjoint des features classiques + DL.

Faiblesses et Limitations

- **Résultats non systématiquement meilleurs**.
- **Dépendance au dataset/config (dropout, embeddings)**.
- **Features simples**, peu d'analyse approfondie de leur contribution.
- **Portée limitée** à une architecture CNN.

Implémentation - Résultats initiaux

- Expérimentation via différents paramètres : dropout, mise en place d'un module d'attention, embedding
- Dans tous les cas : meilleurs résultats sur **TRECQA**, sans attention et avec dropout
- **TRECQA** : MAP allant de -3% à +2.6%, MRR de -3.8 à +3.5
- **WIKIQA** : MAP allant de -2% à +7.2%, MRR de -2.5 à +6.9

Implémentation - Étapes Initiales

- **Récupération du code** : Dépôt GitHub fourni par les auteurs.
- **Premier problème** : Deux implémentations distinctes :
  - Une version en Python 2.
  - Une autre en Python 3, mais incomplète.
- **TRECQA** : Dataset déjà formalisé et prêt à l'emploi.
- **WIKIQA** : Format non pris en charge : travail de préparation nécessaire.

Implémentation - Modifications

- **Second problème** : Partie du code manquante.
  - Génération des identifiants des réponses absente.
- **Notre solution** : Génération via un algorithme simple :
  - Utilisation d'un dictionnaire Réponse : Identifiant.

Implémentation - Nos résultats

System	Attn?	Drop?	TREC QA MAP	TREC QA MRR	WikiQA MAP	WikiQA MRR
Runs (AQUAINT/Wikipedia)						
CNN	No	No	75.25	80.90	**26.37**	**26.84**
Combined Model	No	No	**77.44**	82.19	23.46	23.86
Combined Model	No	Yes	**77.44**	82.19	23.46	23.86
CNN	Yes	No	75.37	80.80	25.09	25.49
Combined Model	Yes	No	76.59	81.45	25.23	25.66
Combined Model	Yes	Yes	76.59	81.45	25.23	25.66
Runs (Google News)						
CNN	No	No	75.18	80.57	25.87	26.24
Combined Model	No	No	76.41	**82.90**	24.82	25.22
Combined Model	No	Yes	76.41	**82.90**	24.82	25.22
CNN	Yes	No	74.15	80.60	25.43	25.95
Combined Model	Yes	No	75.16	79.68	25.34	25.87
Combined Model	Yes	Yes	75.16	79.68	25.34	25.87

Implémentation - Evaluation Utilisateur

- Résultats à relativiser : très petit échantillon
- **Méthode** : Question avec réponses : ordonnancement des réponses
- **Résultat** : % de bon rang : 0.45 (améliorable)
- Le modèle semble bien reconnaître les bonnes et mauvaises réponses mais les ordonne mal

Implémentation - Interprétation

- L'ajout des features apportent bien des améliorations sur le TREC QA.
- Mauvais résultats sur WikiQA : provient sans doute d'une mauvaise reconstruction des données
- Couche d'attention moins efficace comme dans le papier original
- Dropout qui ne change rien : on a pourtant testé avec différentes valeurs...

Expérimentations

Comment représenter la sémantique ?

- LSA ?
  1. Réduction de bruit.
  2. Pas de contexte.
  3. Embedding de document.
- Word2vec ?
  1. Contextuelle.
  2. Nécessite un grand corpus.
  3. Embedding de mot.

Finalement, on optera pour un LSA.

Expérimentations

Le LSA réduit les dimensions, donc pour garder cette avantage, on vectorise en token de taille 5 à 7:

- Gestion des mots nouveaux.
- Sémantique des "racines".

On obtient **1.4M dimensions** au total, puis on applique le LSA pour conserver **10K dimensions**.
Un document devient donc la moyenne de ses phrases (AVG pool).

Expérimentations

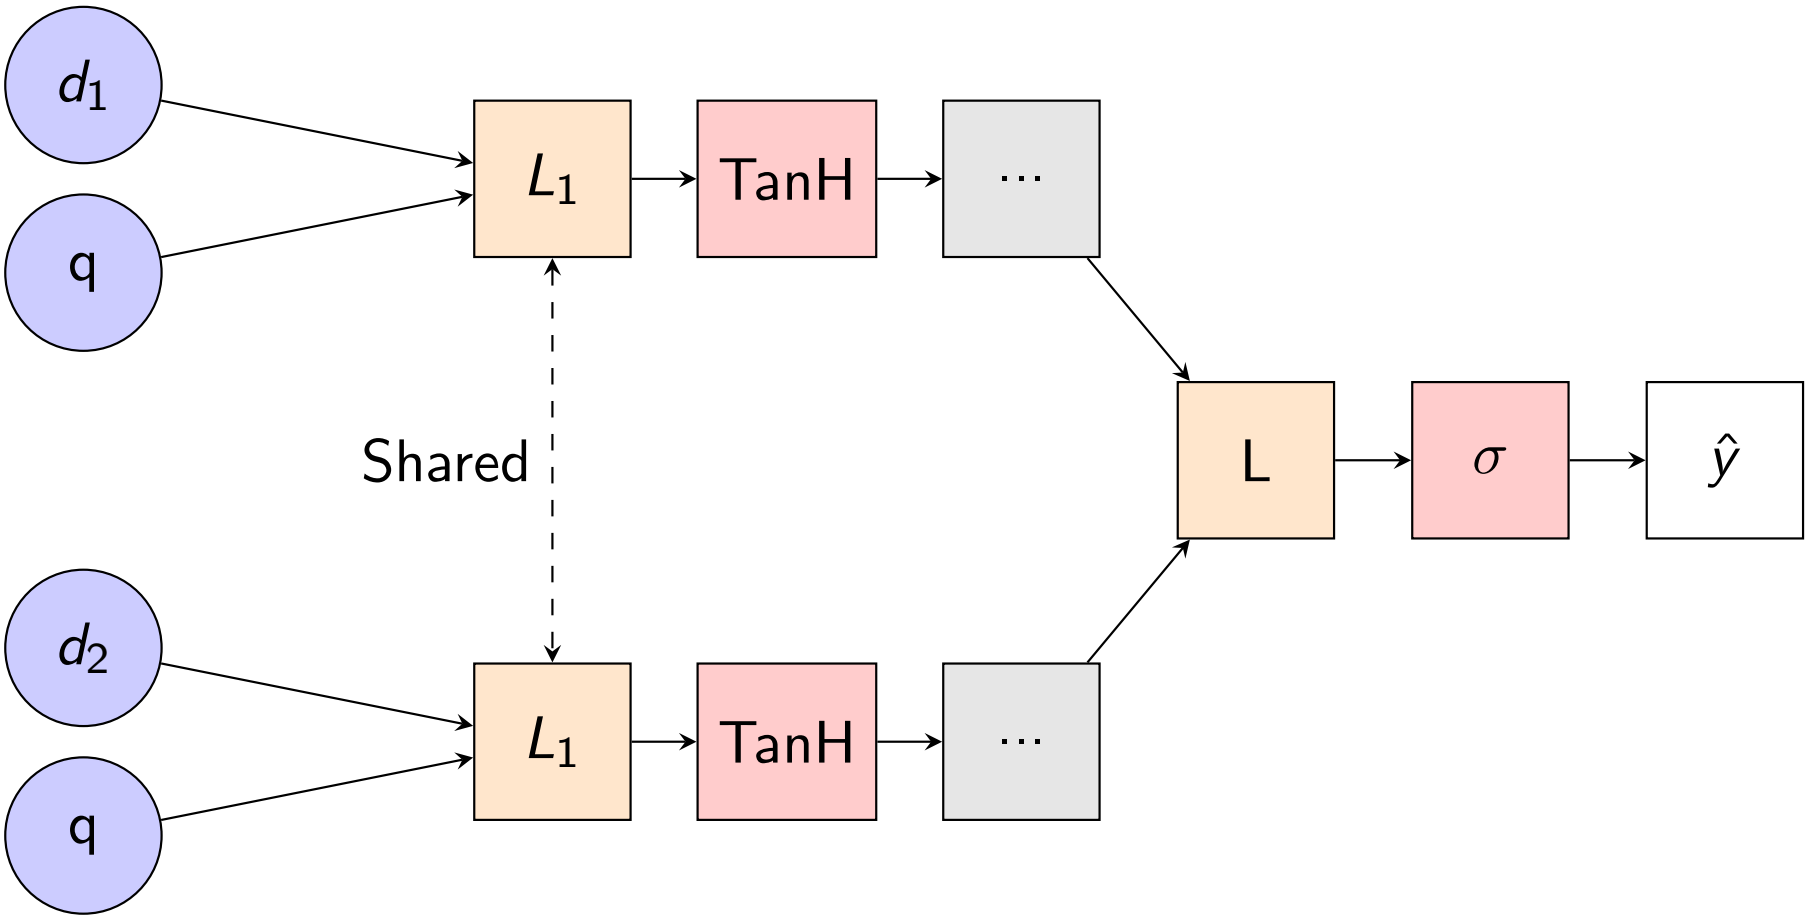

Expérimentations

Maintenant on "sait" trouver le document, mais la phrase ?

- Point-wise: Pas d'interactions.
- Pair-wise: Intéractions et polyvalent.
- List-wise: Encore plus d'interactions mais moins polyvalent.

On opte finalement pour le **pair-wise** faute de temps/matériel.

Expérimentations

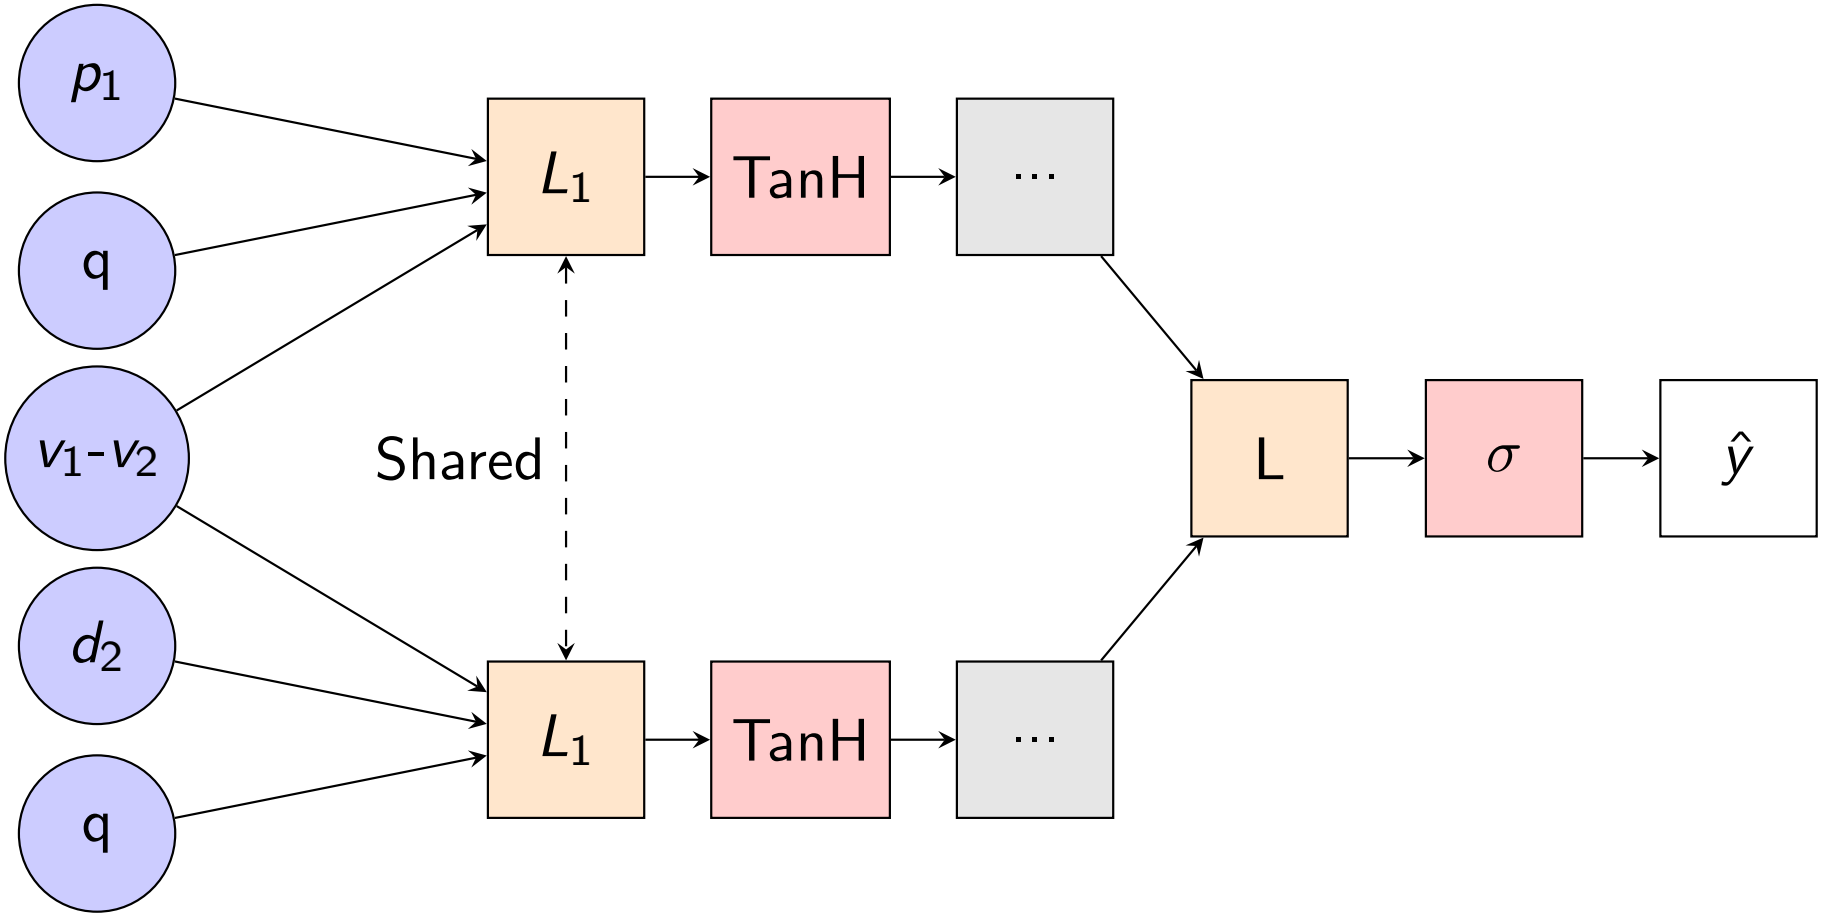

Qu'est ce que v_i ?

On s'inspire de l'article ...

- Length
- ExactMatch
- Alignement max.
- ...
- Similarité Cosinus.

Finalement, $v_i \in \mathbb{R}^{17}$, l'idée est que v_i - v_j puisse encoder le plus proche de la query.

Expérimentations

One vs One (document)

- Accuracy: 67.02%
- F1: 0.56

One vs One (phrase)

- MRR : 14.89
- MAP : 11.37

Expérimentations

Quelle feature et quel impact ?

En mettant simplement les deux features à 0, donc la soustraction n'apportera aucune information, on peut déduire quelle feature a de l'importance dans la prédiction ...

Sans surprise:

- ExactMatch : MRR ± 1.23
- Alignement max: MRR ± 0.56

Expérimentations

Les améliorations:

- Vers un modèle *end-to-end*.
- Embedding des mots.
- List-Wise, donc un réseau par document ?

Conclusion

- Veille scientifique.
- Ré implémenter des articles.
- Essayer des hypothèses.

Merci pour votre attention !

(Et le semestre)